



Data Science

Program Studi Informatika

Sesi 2 – Struktur Data Python, NumPy & Pandas

Syahid Abdullah, S.Si, M.Kom



Outline



**Identitas &
Capaian**



**Struktur Data
Python**



NumPy



Pandas



**Hands-on
& Kuis**



Referensi



Struktur Data Python

list · tuple · dictionary · set



List dan Tuple



List []

- Mutable (dapat diubah setelah dibuat)
- Ordered (urutan dijaga)
- Duplikasi nilai diperbolehkan
- Mendukung berbagai tipe data sekaligus
- Mendukung slicing dan indexing

```
# Membuat dan memanipulasi list
data = [10, 20, 30, 'Python', True]
data.append(40)    # tambah elemen
data[0] = 99       # ubah elemen
print(data[1:3])   # slicing
```



Tuple ()

- Immutable (tidak dapat diubah)
- Ordered (urutan dijaga)
- Lebih cepat & hemat memori dari list
- Cocok untuk data yang tidak berubah
- Dapat digunakan sebagai kunci dictionary

```
# Tuple tidak bisa dimodifikasi
koord = (10.5, -6.8, 'Jakarta')
print(koord[0])    # akses elemen
# koord[0] = 99    # ERROR!
x, y, kota = koord  # unpacking
```



Dictionary dan Set



Dictionary { }

- Mutable dan tidak berurutan (Python ≥ 3.7 : insertion order)
- Menggunakan pasangan key-value
- Key harus unik dan immutable
- Pencarian elemen sangat cepat: $O(1)$
- Fondasi struktur DataFrame di Pandas

```
mahasiswa = {'nama': 'Budi', 'nim': '2024001'}  
mahasiswa['ipk'] = 3.85    # tambah key  
print(mahasiswa['nama'])  # → 'Budi'  
for k, v in mahasiswa.items():  
    print(f'{k}: {v}')
```



Set { }

- Himpunan nilai unik (tidak ada duplikat)
- Tidak berurutan (unordered)
- Operasi himpunan: union, intersect, diff
- Berguna untuk deduplikasi data
- Tidak mendukung indexing

```
kota_a = {'Jakarta', 'Bandung', 'Surabaya'}  
kota_b = {'Bandung', 'Medan', 'Bali'}  
print(kota_a & kota_b)  # intersect  
print(kota_a | kota_b)  # union  
print(kota_a - kota_b)  # difference
```



NumPy: Komputasi Numerik

Array multidimensi · Vektorisasi · Operasi matematika · Fungsi statistik



NumPy Array Pengenalan & Pembuatan

Cara Membuat Array NumPy

```
import numpy as np

# Dari list Python
a = np.array([1, 2, 3, 4, 5])

# Array khusus
z = np.zeros((3, 4))    # nol
o = np.ones((2, 3))     # satu
e = np.eye(3)           # identitas

# Sequence
r = np.arange(0, 10, 2)  # 0,2,4,6,8
l = np.linspace(0, 1, 5) # 5 titik

# Array acak
rng = np.random.default_rng(42)
x = rng.integers(0, 100, (3,3))
```

Atribut Penting ndarray

ndim	Jumlah dimensi array (1D, 2D, 3D...)
shape	Dimensi per sumbu: (3, 4) = 3 baris, 4 kolom
size	Total jumlah elemen dalam array
dtype	Tipe data elemen: int32, float64, bool, dll.
itemsize	Ukuran memori tiap elemen (byte)

Mengapa NumPy?

10–100× lebih cepat dari list Python karena menggunakan C di balik layar dan operasi vektorisasi.



NumPy Array Operasi & Fungsi Statistik

Operasi Vektorisasi

```
a = np.array([1,2,3,4,5])

b = np.array([10,20,30,40,50])

a + b  # → [11,22,33,44,55]

a * 2  # → [2,4,6,8,10]

a ** 2 # → [1,4,9,16,25]

np.sqrt(a)  # akar kuadrat

np.exp(a)   # eksponensial
```

Indexing & Slicing

```
m = np.arange(12).reshape(3,4)

# m:

# [[ 0  1  2  3]
#   [ 4  5  6  7]
#   [ 8  9 10 11]]

m[1, 2]      # → 6

m[0, :]      # baris pertama

m[:, 1]      # kolom kedua

m[m > 5]     # boolean mask
```

Fungsi Statistik

```
data = rng.normal(0, 1, (100,))

np.mean(data)  # rata-rata

np.std(data)   # std deviasi

np.min(data)   # nilai minimum

np.max(data)   # nilai maksimum

np.median(data) # median

np.percentile(data, 75) # Q3
```




Pandas: Manipulasi DataFrame

Series · DataFrame · read_csv · filter · groupby



Pandas Series & DataFrame



Series — Array 1D Berlabel

- Array satu dimensi dengan label (index)
- Dapat berisi tipe data homogen atau campuran
- Index defaultnya 0, 1, 2, ... atau kustom
- Dibangun di atas NumPy ndarray
- Building block dari setiap kolom DataFrame

```
import pandas as pd

s = pd.Series([85, 92, 78, 95],
              index=['Alice', 'Bob', 'Caca', 'Dina'])

print(s['Bob'])    # → 92
print(s.mean())    # → 87.5
print(s[s > 80])   # filter
```



DataFrame — Tabel 2D Berlabel

- Tabel dua dimensi: baris (records) × kolom
- Setiap kolom adalah satu objek Series
- Mendukung tipe data berbeda per kolom
- Dapat dibuat dari dict, list, CSV, database
- Struktur utama analisis data dengan Pandas

```
data = {'nama': ['Ali', 'Budi', 'Caca'],
        'usia': [22, 25, 21],
        'kota': ['Jkt', 'Bdg', 'Sby']}

df = pd.DataFrame(data)

print(df.shape)    # (3, 3)
print(df.dtypes)   # tipe kolom
```



Pandas

Memuat Data CSV & Eksplorasi Awal



analisis_data.ipynb

```
import pandas as pd
import numpy as np

# 1. Muat dataset
url = "https://raw.githubusercontent.com/..."
df = pd.read_csv(url)

# 2. Eksplorasi dasar
print(df.shape)      # (891, 12)
print(df.head())     # 5 baris pertama
print(df.tail(3))    # 3 baris terakhir
print(df.info())     # tipe & missing
print(df.describe()) # statistik deskriptif

# 3. Cek missing values
print(df.isnull().sum()) # per kolom
print(df.isnull().mean()) # proporsi %
```

Fungsi Eksplorasi Pandas

df.shape	Dimensi (n_baris, n_kolom)
df.head(n)	n baris pertama (default 5)
df.info()	Tipe data & jumlah non-null
df.describe()	Statistik deskriptif numerik
df.columns	Daftar nama kolom
df.dtypes	Tipe data per kolom
df.isnull()	Boolean mask missing values
df.nunique()	Jumlah nilai unik per kolom



Pandas Filtering & Seleksi Data

Boolean Indexing

```
# Filter baris berdasarkan kondisi

# Dataset: Titanic

selamat = df[df['Survived']==1]

wanita = df[df['Sex']=='female']

# Kondisi ganda dengan & dan |

filt = df[(df['Age']>18) &

          (df['Pclass']==1)]

# Seleksi kolom tertentu

df[['Name','Age','Survived']]
```

.loc[] dan .iloc[]

```
# .loc - label-based

df.loc[0, 'Name']    # row 0, kol Name

df.loc[0:4, 'Age':'Fare']

# .iloc - integer-based

df.iloc[0, 2]        # baris 0, kolom 2

df.iloc[0:5, 0:3]    # 5 baris, 3 kolom

# Modifikasi via .loc

df.loc[df['Age']<18, 'Kategori']

    = 'Anak-anak'
```

query() & isin()

```
# query() - sintaksis SQL-like

df.query('Age > 18 and Pclass==1')

# isin() - filter multi-nilai

kota = ['Jakarta','Bandung']

df[df['Kota'].isin(kota)]

# str accessor

df[df['Name'].str.contains(

    'Miss')]

df['Name'].str.lower()
```



Pandas Groupby & Agregasi Data

groupby_analysis.ipynb

```
# GroupBy dasar
# Rata-rata usia per kelas penumpang
df.groupby('Pclass')['Age'].mean()

# Beberapa agregasi sekaligus
df.groupby('Pclass').agg(
    jumlah=('Survived','count'),
    selamat=('Survived','sum'),
    rata_usia=('Age','mean')
)

# GroupBy multi-kolom
df.groupby(['Pclass','Sex'])['Survived']
    .mean().unstack()

# Pivot Table (seperti Excel pivot)
pd.pivot_table(df,
    values='Survived',
    index='Pclass', columns='Sex',
    aggfunc='mean')
```

Contoh Output:

Pclass	count	selamat	rata_usia
1	216	136	38.2
2	184	87	29.9
3	491	119	25.1

Fungsi Agregasi Umum

'count'	Jumlah baris per grup
'sum'	Total nilai
'mean'	Rata-rata
'median'	Nilai tengah
'min'/'max'	Nilai minimum/maksimum
'std'/'var'	Standar deviasi / variansi



Aktivitas Hands-On



Langkah-Langkah Praktikum

1

Buka Notebook Baru

Colab

Buat notebook baru di Colab:
"Pertemuan2_[Nama]_[NIM].ipynb"

2

Muat Dataset Titanic

Pandas

`pd.read_csv(URL)` dari GitHub raw CSV. Tampilkan `head()` dan `info()`.

3

Eksplorasi Awal

Analisis

Jawab: berapa baris/kolom? Kolom apa saja? Ada missing values di mana?

4

Filtering

Pandas

Filter penumpang wanita kelas 1. Berapa yang selamat? Rata-rata usianya?

5

Groupby & Agregasi

Pandas

`groupby('Pclass')['Survived'].mean()` — kelas mana tingkat keselamatan tertinggi?

6

Submit via Forum Diskusi 2 di LMS

Tugas

Upload .ipynb ke repo GitHub → submit link ke LMS.



Kuis_P2_NamaMahasiswa.ipynb

```
import pandas as pd
import numpy as np

# ① Muat Dataset Titanic
URL = "https://raw.githubusercontent.com/F8C79E/
      datasciencedojo/datasets/master/
      Titanic/Titanic.csv"
df = pd.read_csv(URL)

# ② Eksplorasi Awal
print(df.shape, df.columns.tolist())
print(df.isnull().sum())

# ③ Filtering – Penumpang Wanita Kelas 1
wk1 = df[(df['Sex']=='female') &
         (df['Pclass']==1)]
print(wk1['Survived'].mean(), wk1['Age'].mean())

# ④ Groupby – Tingkat Keselamatan per Kelas
hasil = df.groupby('Pclass').agg(
    total=('PassengerId', 'count'),
    selamat=('Survived', 'mean'),
).round(3)
print(hasil)
```

Latihan

Pertanyaan Kuis

- Q1** Berapa jumlah baris dan kolom dataset Titanic?
- Q2** Kolom mana yang memiliki nilai kosong (missing)?
- Q3** Berapa persen penumpang yang selamat (Survived=1)?
- Q4** Rata-rata usia penumpang wanita kelas 1 yang selamat?
- Q5** Kelas penumpang mana yang tingkat keselamatan tertinggi?
- Q6** Tampilkan hasil
groupby('Pclass')['Survived'].mean()



Referensi

Buku Teks

- McKinney, W. (2022). Python for Data Analysis: Data Wrangling with Pandas, NumPy, and Jupyter. 3rd ed. O'Reilly.
- VanderPlas, J. (2016). Python Data Science Handbook. O'Reilly. [Free: jakevdp.github.io]
- Bruce, P., Bruce, A. & Gedeck, P. (2020). Practical Statistics for Data Scientists. 2nd ed. O'Reilly.
- Grus, J. (2019). Data Science from Scratch. 2nd ed. O'Reilly.

Artikel Ilmiah

- Harris, C.R., et al. (2020). Array programming with NumPy. Nature, 585, 357–362. doi:10.1038/s41586-020-2649-2
- McKinney, W. (2010). Data Structures for Statistical Computing in Python. Proceedings of the 9th Python in Science Conference, 51–56.
- Van der Walt, S., et al. (2011). The NumPy Array: A Structure for Efficient Numerical Computation. Computing in Science & Engineering, 13(2), 22–30.
- Wickham, H. (2014). Tidy Data. Journal of Statistical Software, 59(10), 1–23.

Dokumentasi & Sumber

- NumPy Documentation (2024): numpy.org/doc
- Pandas Documentation (2024): pandas.pydata.org/docs
- Project Jupyter (2024): jupyter-notebook.readthedocs.io
- Kaggle Datasets — Titanic: kaggle.com/c/titanic/data
- Seaborn Dataset Hub: github.com/mwaskom/seaborn-data



Terima Kasih